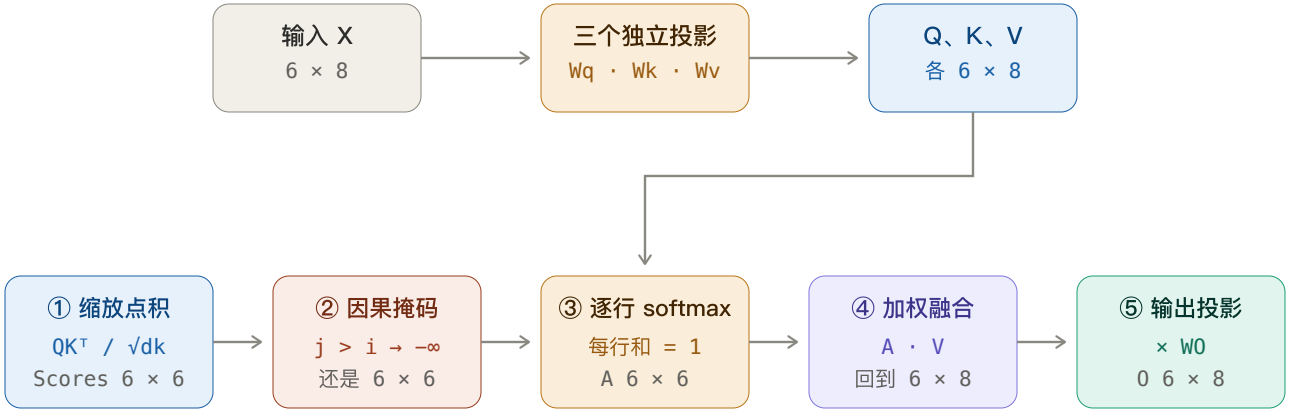
自注意力的运算流水线

进去是 6 个 token 的 8 维向量，中间变成一个 6×6 的"谁看谁"矩阵，出来还是 6 个 8 维向量



- 36 个格子里，只有下三角 21 个合法（6+5+4+3+2+1），其余 15 个被打成 −∞
- 首尾形状都是 (n, d) —— 同形才能加残差，这是能一层层叠下去的前提

注：⑤ 的 WO 是 (d, d)，所以它不会改变形状；多头的"切分—拼接"发生在 ① 之前，见第六节