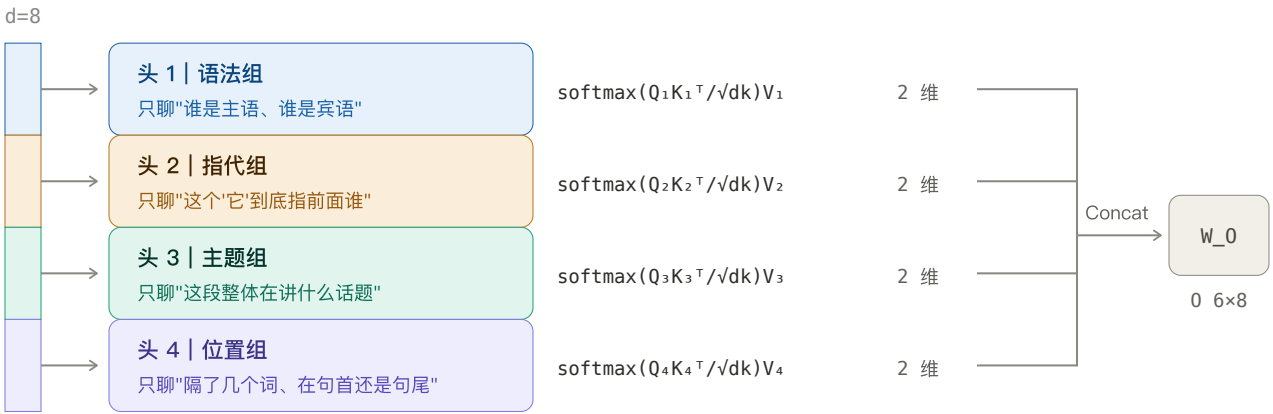
多头注意力：分成 4 个小组同时开小会

一个头只能给"它 → 放实习"打一个分；可它们之间同时存在语法、指代、主题、位置好几种关系



参数量没变：每个头的 Wq 是 (8, 2)，4 个头拼起来正好是 (8, 8)，和单头一样

所以多头不是"多花参数"，是"把同样的参数切成几份用"；但切太细每份太窄，也学不出东西

上图是 d=8 切成 4 个 2 维头的示意；真实模型常见 d=4096、h=32，每个头 128 维