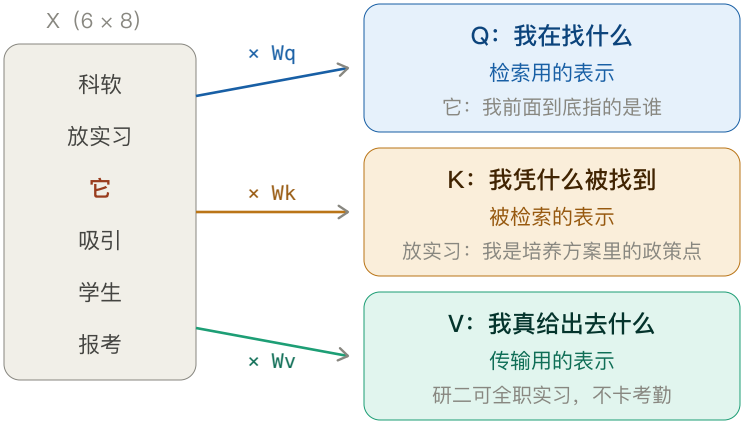
一个 token，三份身份

同一份输入，乘三个不共享的权重矩阵，变成三种完全不同的用途



为什么不能共用一个矩阵？

① 检索的表示和传输的内容被强行绑死。"我为什么被选中"和"选中后给出什么"本来是两件事，绑在一起就互相拖累。

② 方向性消失。"我找你"和"你找我"会算出同一个分数，注意力矩阵被迫对称——而"谁在指代谁"天生是有向的。

③ 三个 W 都是 (8, 8)，参数不共享，各有各的梯度，各学各的。

算分用的是 Q 和 K，混合用的是 V：

$\text{Scores} = Q \cdot K^{\top} / \sqrt{dk}$ → 谁和谁匹配

$O = \text{softmax}(\text{Scores}) \cdot V$ → 匹配上之后拿到什么

K 只参与打分，不进加权和